Львівський національний університет імені Івана Франка · Факультет електроніки та комп'ютерних технологій · Кафедра системного проєктування

Вибрані розділи науки про дані · 2026–2027 н. р.

Лабораторна робота 11

Векторна база даних та RAG

- **Тема:** ЛР 11. Векторна база даних та RAG
- **Лекція:** 11-й тиждень, лекція 11 «Векторні бази даних, RAG та GraphRAG»
- **Тривалість:** 2 год аудиторно + ≈ 4 год самостійної підготовки й оформлення
- **Оцінювання:** максимум 2 бали = 5 результатів × 0.3 бала (разом 1.5) + 0.5 бала за захист (5 запитань × 0.1)
- **Термін здачі та захисту:** до кінця 12-го тижня
- **Інструменти:** Python, FAISS/Chroma, LLM API
- **Дані / вхід:** корпус ≥ 20 документів (інструкції, wiki, статті; українською/англійською) та 20 питань із відомими джерелами

1. Мета роботи

Побудувати векторний індекс і RAG-систему над власним корпусом документів: chunking, embeddings, пошук, відповідь із цитуванням, порівняння BM25, dense і гібридного пошуку.

2. Які навички ви наберете

- розбивати документи на фрагменти з метаданими;
- будувати векторний індекс (FAISS/Chroma) і виконувати пошук із фільтрацією;
- проєктувати RAG-промпт із цитуванням та відмовою;
- порівнювати методи пошуку метриками recall@k.

3. Підготовка

- Опрацюйте лекцію 11 та джерела [13, 19].
- Встановіть faiss-cpu (або chromadb), sentence-transformers, rank_bm25.
- Підготуйте корпус (перевірте ліцензії) та список питань із очікуваним документом.

4. Порядок виконання

Робота складається з п'яти результатів. Кожен результат — самостійна частина (таблиця, схема, алгоритм, модель, код, метрики тощо) і оцінюється окремо: 0.3 бала — виконано повністю; 0.15 — виконано частково; 0 — не виконано. Виконуйте результати послідовно: кожен наступний використовує попередній.

Результат 1. Chunking і метадані

Крок 1. Завантажте документи й очистіть текст (прибрати колонтитули, зайві пробіли).

Крок 2. Реалізуйте дві стратегії: фіксований розмір (400 токенів, overlap 15 %) та за структурою (заголовки/абзаци).

Крок 3. До кожного фрагмента додайте метадані: документ, розділ, сторінка, мова.

Крок 4. Порівняйте стратегії: кількість фрагментів, середня довжина, приклади «поганих» розрізів.

Що зараховується. Повністю (0.3 бала): дві стратегії, метадані, порівняння з прикладами. Частково (0.15 бала): одна стратегія або без метаданих. Інакше — 0.

Результат 2. Векторний індекс і пошук

Крок 1. Оберіть модель embeddings (багатомовну, напр. paraphrase-multilingual-MiniLM) і нормалізуйте вектори.

Крок 2. Побудуйте індекс (faiss.IndexFlatIP або Chroma collection) і збережіть його на диск.

Крок 3. Реалізуйте пошук top-k із фільтрацією за метаданими (мова/документ).

Крок 4. Перевірте на 5 запитах: чи релевантні фрагменти в top-3; запишіть спостереження.

Що зараховується. Повністю (0.3 бала): індекс збережено, пошук із фільтрацією, перевірка на 5 запитах. Частково (0.15 бала): індекс без фільтрації або без перевірки якості. Інакше — 0.

Результат 3. RAG-відповіді з цитуванням

Крок 1. Напишіть промпт: відповідати лише за фрагментами, цитувати джерела [id], за відсутності відповіді — «Недостатньо даних».

Крок 2. Реалізуйте конвеєр: запит → embedding → top-k → промпт → LLM → відповідь із джерелами.

Крок 3. Запустіть на 10 питаннях (включно з 2 питаннями без відповіді в корпусі).

Крок 4. Перевірте цитати автоматично: чи наведений фрагмент справді містить твердження (рядковий збіг або порівняння).

Що зараховується. Повністю (0.3 бала): цитування, відмова, 10 питань, автоматична перевірка цитат. Частково (0.15 бала): без відмови або без перевірки цитат. Інакше — 0.

Результат 4. Порівняння BM25, dense та гібриду

Крок 1. Реалізуйте BM25 (rank_bm25) і dense-пошук на тих самих фрагментах.

Крок 2. Реалізуйте гібрид через RRF: score = Σ 1/(60 + rank).

Крок 3. На $\geq$ 20 питаннях обчисліть recall@1, @3, @5 для трьох методів.

Крок 4. Побудуйте таблицю й графік; поясніть, на яких типах питань кожен метод виграє (коди, синоніми, довгі запити).

Що зараховується. Повністю (0.3 бала): три методи, $\geq$ 20 питань, recall@k, пояснення. Частково (0.15 бала): два методи або менше 20 питань. Інакше — 0.

Результат 5. Аналіз помилок і висновки

Крок 1. Для питань, на які не знайдено відповіді, визначте причину: немає в корпусі; chunking; embeddings; фільтр; промпт.

Крок 2. Запропонуйте та протестуйте одне покращення (інший chunk, rerank, переписування запиту) і виміряйте ефект.

Крок 3. Запишіть підсумкову конфігурацію й обмеження.

Крок 4. Заповніть README і декларацію ШІ.

Що зараховується. Повністю (0.3 бала): категоризація помилок, перевірене покращення з цифрами. Частково (0.15 бала): помилки перелічено без причин або без перевірки покращення. Інакше — 0.

5. Вимоги до звіту та файлів

- Звіт за шаблоном «Шаблон звіту до лабораторної роботи»; для кожного результату — розділ із описом кроків, фрагментами коду, таблицями, рисунками та висновком.
- Код (ноутбук/скрипти) запускається з нуля; є README (версії, залежності, фіксований seed, інструкція запуску).
- Файли: ЛР11_{Прізвище}_{група}.pdf та .zip; ключі API, паролі, персональні дані не включати.
- Здача в Moodle до терміну; захист — усно на лабораторному занятті.

6. Оцінювання

- **Результати 1–5:** по 0.3 бала (максимум 1.5): повністю — 0.3; частково — 0.15; не виконано — 0. Умови наведено під кожним результатом.
- **Захист і опитування:** 0.5 бала (5 запитань по 0.1 бала); студент також має пояснити будь-яку частину роботи й за вимогою змінити її «наживо».
- **Запізнення** (до закриття модуля): бали за результати множаться на 0.8; після закриття модуля робота не приймається, крім поважних причин.
- **Не пояснив роботу:** бали за результати зменшуються вдвічі (до кратних 0.15).
- **Порушення доброчесності** (списування, вигадані дані чи джерела, неоголошене використання ШІ): робота не зараховується.
- **Декларація використання ШІ** обов’язкова (інструмент, призначення, запити, як перевірено); без неї результати не зараховуються.

7. Контрольні питання (захист)

1. Що таке embeddings і косинусна схожість?
2. Чим відрізняються Flat, IVF та HNSW?
3. Навіщо потрібне перекриття (overlap) у chunking?
4. Що таке RRF?
5. Які метрики пошуку ви використали й що вони показують?

8. Академічна доброчесність і використання ШІ

Робота виконується самостійно. Генеративний ШІ дозволено як допоміжний інструмент за умови декларації й розуміння кожної частини роботи. Списування, вигадані дані чи джерела, неоголошене використання ШІ — порушення доброчесності.

9. Рекомендовані джерела

- [13] Lewis et al. RAG; [19] Jurafsky & Martin; документація FAISS: https://github.com/facebookresearch/faiss; Chroma: https://docs.trychroma.com